CIS COLLEGE
IRAQ INTERNATIONAL

AI DIPLOMA / FINAL DATA ANALYTICS PROJECT

تحليل جودة بيانات أجهزة الاستشعار الصناعية

Factory Sensor Telemetry
Data Quality · Cleaning · Exploratory Analysis

إعداد الطالب : Mohammed Muayad Shakir

المجال : Data Analytics & Data Preprocessing

نوع المشروع : مشروع تطبيقي نهائي ضمن دبلوم هندسة الذكاء الاصطناعي

تاريخ التقرير : 3 نوفمبر 2026

Tools & Technologies : Python · Pandas · NumPy · Matplotlib · Jupyter Notebook

8,000	12	3	4
سجل بعد التنظيف	جهاز استشعار	مواقع تشغيلية	مخططات تحليلية

نطاق الدراسة : فحص البيانات الاصطناعية وتقييم جودتها، وتنفيذ عمليات تنظيف قابلة للتحقق، وتحليل الأنماط والاتجاهات، دون افتراض أعطال هندسية مثبتة

REPORT STRUCTURE / CONTENTS

محتويات التقرير

يوثق التقرير البيانات والمنهجية ونتائج الفحص والتحليل والتصورات البيانية وحدود الاستنتاج، استنادا إلى ملفات المشروع ودفاتره البرمجية

1. الملخص التنفيذي — Executive Summary	2
2. وصف البيانات ونطاق الدراسة — Dataset & Scope	2
3. منهجية العمل — Methodology	4
4. نتائج تدقيق جودة البيانات — Data Quality Findings	5
5. التنظيف ونتائج التحقق — Cleaning & Validation	6
6. نتائج التحليل الاستكشافي — Exploratory Results	7
7. التصورات البيانية — Data Visualization	11
8. المناقشة والاستنتاجات — Discussion & Findings	12
9. حدود الدراسة — Limitations	13
10. التوصيات والتطوير المستقبلي — Recommendations	13
11. ملفات المشروع والمراجع — Project Files & References	14
12. الخلاصة — Conclusion	14

المؤشرات المعروضة وصفية ضمن مجموعة بيانات اصطناعية. لا تستخدم نتائج الفحص بوصفها دليلا مستقلا على وقوع أعطال فعلية أو معيارا هندسيا للتشغيل الآمن

1. الملخص التنفيذي — Executive Summary

يتناول هذا المشروع تقييم جودة بيانات أجهزة استشعار صناعية اصطناعية، وتنظيف مشكلات التنسيق والتكرار، ثم تحليل القياسات للكشف عن الأنماط والفروق بين الأجهزة والمواقع خلال فترة التسجيل. استخدمت لغة Python ومكتبات Pandas وNumPy وMatplotlib، مع توثيق مراحل العمل والاختبارات داخل دفترين مستقلين من Jupyter Notebook

تتكون مجموعة البيانات الأصلية من **8,000 سجل و8 أعمدة** تمثل قراءات **12 جهازا في 3 مواقع**. ولأغراض التدريب على معالجة البيانات، أعدت نسخة عمل خام تحتوي على **8,020 سجلا** بعد إضافة مشكلات جودة مقصودة. أسفرت المعالجة عن نسخة منظفة تضم **8,000 سجل**، مع المحافظة على القيم المفقودة والقراءات المتطرفة التي لا يوجد دليل كاف يبرر تعويضها أو حذفها

أظهر الفحص وجود **20 تكرارا كاملا** و**40 قيمة مفقودة**، إلى جانب اختلافات تنسيق في بعض الأعمدة. وكشف التحليل عن ارتباط وصفي موجب بين الحرارة والاهتزاز، وعن تركز معظم قراءات الاهتزاز المتطرفة في جهازين، فضلا عن **8 فجوات زمنية طويلة** موجودة في البيانات الأصلية أيضا. كما أظهر فحص إضافي أن عدد القراءات المصنفة كقيم متطرفة يتأثر بطريقة اختيار الحدود الإحصائية

الخلاصة الرئيسية : حقق المشروع أهداف فحص الجودة والتنظيف والتحقق والتحليل الاستكشافي، مع بقاء النتائج ضمن إطار البيانات الاصطناعية. لا تمثل المؤشرات الإحصائية تشخيصا مثبتا لأعطال ميكانيكية أو توقعا لأعطال مستقبلية

2. وصف البيانات ونطاق الدراسة — Dataset & Scope

2.1 المصدر وطبيعة البيانات

استخدمت مجموعة Factory Sensor Telemetry من Datanemics، وهي مجموعة **Synthetic Dataset** تحاكي قراءات أجهزة استشعار صناعية، ويعرض المصدر ترخيصها بوصفه CC0 1.0

تغطي البيانات الفترة من **1 يناير إلى 28 فبراير 2023**. توزعت الأجهزة على ثلاثة مواقع يشار إليها بالرموز الآتية :

- `NOR` — أربعة أجهزة
- `RIV` — أربعة أجهزة
- `SLT` — أربعة أجهزة

تتضمن البيانات الأصلية بعض الأنماط غير المعتادة والفجوات الزمنية. لذلك يجري التمييز في هذا التقرير بين **مشكلات الجودة المضافة إلى نسخة التدريب** وبين **الخصائص الموجودة أصلا في البيانات الاصطناعية**

2.2 ملفات البيانات المعتمدة

الملف	الاستخدام	عدد السجلات
original_data.csv	مرجع البيانات الاصطناعية الأصلية المحفوظ دون تعديل	8,000
raw_data.csv	نسخة العمل الخام التي أضيفت إليها مشكلات جودة للتدريب	8,020
cleaned_data.csv	البيانات الناتجة عن التنظيف والتحقق	8,000

لا يتضمن المشروع سكربتا مستقلا لإعادة إنشاء مشكلات الجودة المضافة من الملف الأصلي. تبدأ إعادة تنفيذ خطوات الدفترين من ملف raw_data.csv المرفق، ويظل original_data.csv مرجعا مستقلا للمقارنة

2.3 الأعمدة ووحدات القياس

العمود	المعنى	الوحدة أو طبيعة القيمة
reading_at	تاريخ ووقت تسجيل القراءة	UTC حسب وصف المصدر
device_id	معرف الجهاز	رمز نصي
site	الموقع التابع له الجهاز	NOR / RIV / SLT
status	تصنيف الحالة المسجلة	OK / WARN / FAULT
temp_c	درجة الحرارة	°C
humidity_pct	الرطوبة النسبية	%
vibration_mm_s	سرعة الاهتزاز من نوع RMS	mm/s
rpm	سرعة الدوران	دورة في الدقيقة

ملاحظة فنية : يصف المصدر وقت التسجيل بأنه UTC، إلا أن قيم التاريخ داخل CSV لا تتضمن منطقة زمنية صريحة لكل سجل. احتفظ المشروع بالتوقيت كما ورد دون تحويله إلى توقيت محلي. كذلك يشير RMS إلى **Root Mean Square** في توصيف قياس سرعة الاهتزاز

2.4 أسئلة الدراسة

تتمحور الدراسة حول سؤال رئيسي تتفرع منه مجموعة من الأسئلة التي تغطي تقييم جودة البيانات ومعالجتها وتحليل القياسات التشغيلية

السؤال الرئيسي :

ما مدى جودة بيانات حساسات المصنع، وما الأنماط والاتجاهات التي تظهر في القياسات عبر الأجهزة والمواقع والفترة الزمنية المدروسة؟

الأسئلة الفرعية :

تسعى الدراسة للإجابة عن الأسئلة التالية :

1. ما المشكلات الموجودة في جودة البيانات الخام، وما حجم كل مشكلة؟
2. ما إجراءات التنظيف التي يمكن تنفيذها بأمان، وكيف يتم التحقق من صحة نتائجها؟
3. كيف تختلف قياسات الحرارة والاهتزاز والرطوبة وسرعة الدوران بين الأجهزة والمواقع؟
4. ما الاتجاهات الزمنية والفجوات والقيم المتطرفة الظاهرة في البيانات؟
5. ما حدود تفسير الأنماط المكتشفة، وما المتطلبات الإضافية اللازمة لاستخدام البيانات في تعلم الآلة مستقبلا؟

3. منهجية العمل — Methodology

اعتمد المشروع مسارا مترابطا يبدأ بفهم البيانات الخام وتدقيق جودتها، ثم تنظيف المشكلات القابلة للمعالجة والتحقق منها، وينتهي بالتحليل الاستكشافي وعرض النتائج بصريا. فصل التنفيذ إلى دفترين لتوضيح مسؤولية كل مرحلة ولإتاحة مراجعة القرارات والنتائج بصورة مستقلة

3.1 تدقيق جودة البيانات — Data Quality Assessment

شمل التدقيق فحص أبعاد الجدول وأنواع الأعمدة والتكرارات الكاملة ومفاتيح الجهاز والتاريخ والقيم المفقودة، فضلا عن تنسيق التصنيفات وسرعة الدوران. كما استخدم التحليل الإحصاءات الوصفية وطريقة المدى الربيعي **IQR** لتحديد القراءات غير المعتادة إحصائيا

3.2 تنظيف البيانات — Data Cleaning

نفذ التنظيف في دفتر `02_data_cleaning_validation.ipynb` ، بدءا من نسخة البيانات الخام، دون إجراء تعديلات على الملف المرجعي الأصلي. تضمنت المعالجة إزالة التكرارات الكاملة وتحويل التاريخ وتوحيد الصيغ النصية ومعالجة التنسيق الرقمي، ثم ترتيب السجلات وحفظ النسخة المنظفة

3.3 التحقق — Data Validation

استخدمت اختبارات `assert` للتحقق من عدد السجلات وعدم تكرار المفاتيح وأنواع الأعمدة واتساق التصنيفات ومواقع القيم المفقودة. كما أعيد تحميل الملف المنظف بعد الحفظ وفحص تطابق المحتوى والأنواع المطلوبة وفق إعدادات القراءة

وأضيف اختبار مستقل لمقارنة النسخة التحليلية المستخدمة في دفتر الفحص مع `cleaned_data.csv` بعد توحيد التنسيق وترتيب السجلات. نجح الاختبار في مقارنة **8,000 سجل** وجميع الأعمدة ضمن هامش عددي صغير، مع السماح بفروق التمثيل البرمجي لأنواع البيانات

3.4 التحليل الاستكشافي — Exploratory Data Analysis

نفذ التحليل في دفتر `01_data_quality_analysis.ipynb` ، وشمل الإحصاءات الوصفية والتصفية والترتيب والتجميع باستخدام `groupby()` والجداول المحورية `Pivot Table` ، وتحليل الارتباطات والاتجاهات اليومية والفجوات الزمنية

أنشئ العمود المشتق `reading_day` من تاريخ القراءة داخل بيانات التحليل الزمني لغرض التجميع بحسب اليوم، دون إضافته إلى ملف البيانات الخام أو المنظفة

3.5 بيئة التنفيذ وإعادة إنتاج النتائج

نجحت إعادة تشغيل الدفترين من نواة Jupyter جديدة باستخدام **Python 3.14.7**، مع إصدارات المكتبات الموثقة في ملف `requirements.txt` : **Pandas 3.1.0** و**NumPy 2.5.4** و**Matplotlib 3.11.2** و**ipykernel 7.4.0**

تستخدم الدفاتر مسارات نسبية انطلاقا من مجلد `notebooks` ، ويؤدي تشغيل دفتر التنظيف إلى إعادة حفظ `cleaned_data.csv` . لذلك يجب مراعاة آثار إعادة التنفيذ عند إعداد حزمة التسليم، وتوثق تعليمات التشغيل التفصيلية في `README.md`

4. نتائج تدقيق جودة البيانات — Data Quality Findings

4.1 المشكلات المكتشفة في نسخة العمل الخام

عنصر الفحص	النتيجة
حجم البيانات الخام	8,020 صفا × 8 أعمدة
الصفوف المكررة بالكامل	20
القيم المفقودة في القياسات	40
القيم المفقودة في كل عمود قياس	10
اختلافات تنسيق رموز الموقع	12
اختلافات تنسيق حالات التشغيل	12
قيم سرعة الدوران المحتوية على فواصل آلاف	12
التواريخ غير الصالحة	0
الفجوات الزمنية الطويلة المرصودة	8

تفسير النتيجة : تعد مشكلات التكرار وفواصل الأرقام وتباين كتابة التصنيفات قابلة للمعالجة بصورة مباشرة. أما القيم المفقودة والفجوات والقراءات المتطرفة فلا يمكن افتراض قيم بديلة لها أو إلغاؤها دون معلومات موثوقة إضافية

4.2 توزيع القيم المفقودة

توجد **40 قيمة مفقودة** موزعة بالتساوي على أربعة أعمدة رقمية :

العمود	القيم المفقودة
temp_c	10
humidity_pct	10
vibration_mm_s	10
rpm	10
الإجمالي	**40**

توزعت القيم المفقودة بحسب المواقع إلى **26 قيمة في** NOR و**8 في** RIV و**6 في** SLT . يشير هذا الاختلاف إلى عدم تساوي توزيع القيم المفقودة بين المواقع، لكنه لا يثبت سببا تشغيليا محددا

5. التنظيف ونتائج التحقق — Cleaning & Validation

5.1 سجل قرارات التنظيف

المشكلة	المعالجة المعتمدة	المبرر
تكرار 20 سجلا بالكامل	حذف السجلات المكررة	منع احتساب القراءة أكثر من مرة
تخزين التاريخ كنص	تحويل reading_at إلى نوع زمني	دعم الفرز والحساب الزمني
اختلافات site و status	إزالة المسافات الزائدة وتوحيد الأحرف	اتساق التجميع والتصنيف
فواصل آلاف في rpm	إزالة الفواصل ثم التحويل الرقمي	ضمان صحة العمليات العددية
القيم المفقودة	الاحتفاظ بها دون تعويض	عدم اختلاق قياسات غير موثقة
القيم المتطرفة	الاحتفاظ بها دون حذف تلقائي	غياب دليل هندسي على كونها أخطاء
الفجوات الزمنية	عدم إنشاء سجلات بديلة	غياب مرجع يؤكد القراءات غير المسجلة

رتبت السجلات بعد المعالجة حسب تاريخ القراءة ومعرف الجهاز، ثم حفظت في cleaned_data.csv

5.2 نتائج التنظيف

مؤشر التحقق	النتيجة بعد التنظيف
عدد السجلات	8,000
عدد الأعمدة	8
التكرارات الكاملة	0
القيم المفقودة	40، محفوظة دون تعويض
تنسيق المواقع والحالات	موحد
نوع الأعمدة الرقمية والتاريخ عند إعادة القراءة	اجتاز الاختبارات
تطابق الملف المحفوظ مع ناتج التنظيف	اجتاز الاختبار
تكافؤ البيانات التحليلية والمنظفة بعد توحيد التنسيق	اجتاز الاختبار

توضيح منهجي : صيغة CSV لا تخزن أنواع البيانات البرمجية بصورة مستقلة؛ تتحدد هذه الأنواع عند إعادة قراءة الملف وفق الإعدادات المستخدمة. كما أن نجاح فحص التطابق يسمح بفروق طفيفة محددة في تمثيل الأنواع والأرقام، ولا يمثل تحققا هندسيا من صحة القياسات

6. نتائج التحليل الاستكشافي — Exploratory Results

6.1 التصفية والتجميع

استخدم المشروع تصفيات ذات أهداف مختلفة، من بينها عزل قراءات حالة التشغيل `FAULT` ، وقراءات الحرارة الأعلى من المئين التسعين، وقراءات الموقع `NOR` . وأجريت تجميعات ومقارنات بحسب الموقع والجهاز والحالة، إضافة إلى ترتيب الأجهزة وإنشاء جدول محوري لمتوسط الاهتزاز

مؤشر التصفية	النتيجة
قراءات الحالة `FAULT`	124
المئين التسعون للحرارة	45.151 °C
القراءات الأعلى من المئين التسعين	799
قراءات الموقع `NOR`	2,823

من بين **799 قراءة** أعلى من المئين التسعين للحرارة، سجلت **414 قراءة** بحالة `OK` و**274** بحالة `WARN` و**111** بحالة `FAULT` . ويبين ذلك أن تصنيف الحرارة المرتفعة نسبيا لا يطابق وحده تصنيفات حالات التشغيل

6.2 القيم المتطرفة — IQR

استخدم فحص القيم المتطرفة الأصلي حدودا عامة محسوبة لكل متغير من جميع قراءاته الصالحة بعد إزالة التكرارات

القياس	القراءات المتطرفة	النسبة التقريبية من 8,000 سجل
الحرارة	89	1.1%
الرطوبة	49	0.6%
الاهتزاز	677	8.5%
سرعة الدوران	61	0.8%

تركزت **650 قراءة اهتزاز متطرفة من أصل 677** في جهازين : **419 قراءة في** `MCH-04` و**231 قراءة في** `MCH-10` ، أي نحو **96%** من إجمالي قراءات الاهتزاز المتطرفة وفق هذا التعريف

هذا التركز يحدد موضعا يستحق الدراسة والمقارنة، لكنه لا يعني أن جميع القراءات المصنفة متطرفة غير صحيحة أو أن الجهازين تعرضا لأعطال مثبتة

6.3 مقارنة منهجيتين لتحديد القيم المتطرفة للحرارة

استخدمت مقارنة إضافية لبيان تأثير اختيار **المرجع الذي تشتق منه حدود IQR**. في الطريقتين الجديدتين اشتقت الحدود من القراءات المسجلة بالحالة `OK` ، ثم طبقت الحدود على جميع قراءات الحرارة :

- **الطريقة الأولى :** حدود عامة واحدة مشتقة من قراءات `OK` في جميع الأجهزة
- **الطريقة الثانية :** حدود مستقلة لكل جهاز، مشتقة من قراءاته المسجلة بالحالة `OK`

عدد القراءات	نتيجة المقارنة
133	متطرفة بالحدود العامة المستندة إلى `OK`
89	متطرفة بحدود كل جهاز المستندة إلى `OK`
88	متطرفة بالطريقتين معا
45	متطرفة بالحدود العامة فقط
1	متطرفة بحدود الجهاز فقط
46	مختلفة التصنيف بين الطريقتين

النتيجة التفسيرية : الفرق بين الإجماليين هو **44 قراءة**، بينما يبلغ اختلاف تصنيف السجلات نفسها **46 قراءة**، لأن إحدى القراءات صنفت متطرفة بحدود الجهاز فقط. كما سجل الجهاز `MCH-06` قراءتين مختلفتي التصنيف رغم تطابق عدد القراءات المتطرفة له بالطريقتين

تمييز أساسي : العدد **89** في فحص IQR الأصلي للحرارة مشتق من جميع قراءات الحرارة الصالحة، بينما العدد **89** في الطريقة الثانية أعلاه ناتج عن حدود خاصة بكل جهاز مشتقة من قراءات `OK` . تطابق العددين لا يعني تطابق طريقة الحساب أو هوية السجلات

6.4 متوسط الاهتزاز بين المواقع

الموقع	متوسط الاهتزاز
NOR	3.3592 mm/s
RIV	2.8044 mm/s
SLT	2.6043 mm/s

سجل الموقع NOR أعلى متوسط عام، لكن متوسطه انخفض إلى **2.7033 mm/s** عند استبعاد قراءات الجهازين MCH-04 و MCH-10 من **المقارنة التحليلية فقط**. وأصبح المتوسط الناتج أقل من متوسط موقع RIV

تبين هذه النتيجة أن متوسط الموقع يتأثر بقوة بقراءات أجهزة معينة، لذلك لا يصح افتراض أن جميع أجهزة NOR تتبع المستوى نفسه من الاهتزاز. لم تحذف قراءات الجهازين من الملفات الأصلية أو المنظفة

6.5 الارتباط بين الحرارة والاهتزاز

مجموعة القراءات	معامل ارتباط بيرسون
البيانات التحليلية	0.6232
القراءات المسجلة بالحالة OK فقط	0.3093

يشير الارتباط الموجب إلى ميل الحرارة والاهتزاز إلى الارتفاع معا في البيانات المدروسة. لكن انخفاض المعامل عند الاقتصار على الحالة OK يوضح أن قوة العلاقة تتأثر بتكوين مجموعة القراءات المستخدمة في الحساب

لا يثبت معامل الارتباط أن ارتفاع الحرارة تسبب بارتفاع الاهتزاز أو العكس، ولا يكفي وحده لتشخيص حالة الجهاز

6.6 اتساق تصنيفات الحالة مع الاهتزاز

أجري اختبار استكشافي لمقارنة تصنيفات status بحدين للاهتزاز : **4.2** و**5.5 mm/s**. طابقت التصنيفات القاعدة المختبرة في **7,990 قراءة** تتوفر فيها قيمة اهتزاز، دون اختلافات

التصنيف	القراءات المطابقة للقاعدة
OK	7,387
WARN	481
FAULT	122
الإجمالي القابل للفحص	**7,990**

بقيت **10 قراءات** غير قابلة للفحص بهذه القاعدة بسبب فقدان قيمة الاهتزاز، رغم وجود حالة مسجلة لها : **7 بحالة** OK و**1 بحالة** WARN و**2 بحالة** FAULT

حدود الاستنتاج : يثبت الاختبار اتساق القيم الصالحة مع القاعدة المختبرة، ولا يثبت أن القاعدة هي الآلية الأصلية لتوليد التصنيفات أو أنها معيار هندسي معتمد للأعطال

6.7 الفجوات الزمنية وتغطية الأجهزة

حدد التحليل **8 فجوات زمنية طويلة** في أربعة أجهزة بموقع RIV :

MCH-02 · MCH-05 · MCH-08 · MCH-11

سجل كل جهاز فجوتين. بلغت مدة أربع فجوات **4 أيام و22 ساعة**، وبلغت مدة الأربع الأخرى **5 أيام**. وظهرت الفجوات خلال فترتين في يناير وفبراير 2023، وتأكد وجودها في original_data.csv قبل إضافة مشكلات جودة نسخة العمل

يمتد نطاق البيانات عبر **59 يوما**. ظهرت قراءات على امتداد الأيام الـ59 لثمانية أجهزة، بينما ظهرت قراءات في **51 يوما** لكل جهاز من الأجهزة الأربعة المتأثرة بالفجوات. لا تعني التغطية اليومية بحد ذاتها توافر جميع القراءات المتوقعة في ساعات اليوم

عند افتراض فاصل معتاد قدره **ساعتان بين قراءتين متتاليتين للجهاز الواحد**، بلغ التقدير **468 قراءة محتملة غير مسجلة** داخل هذه الفجوات. وهو تقدير مشروط بنمط التسجيل المرصود، وليس عددا مؤكدا من القراءات المفقودة أو دليلا على سبب انقطاع التسجيل

6.8 اتجاه الاهتزاز اليومي

أظهرت المتوسطات اليومية ميلا تصاعديا للجهازين التاليين :

الجهاز	الميل التقريبي اليومي
MCH-04	0.0540 mm/s/day
MCH-10	0.0487 mm/s/day

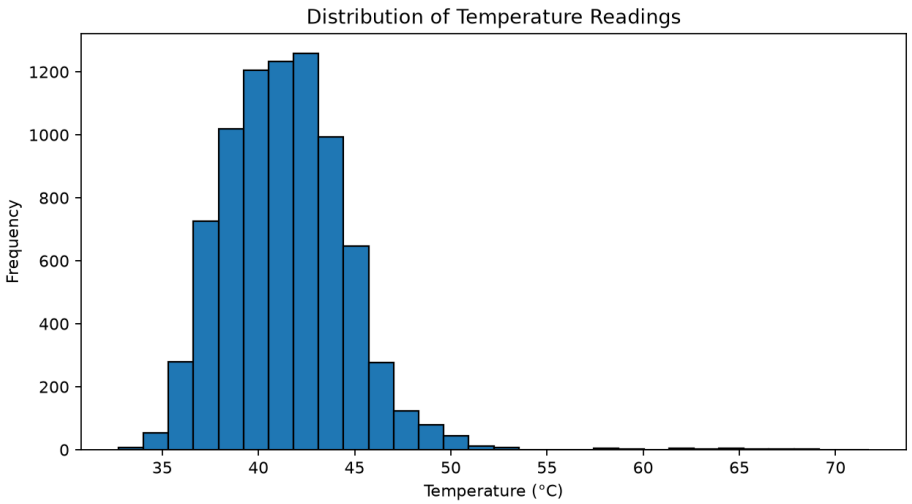
استخدمت عتبة **0.02 mm/s/day** معيارا استكشافيا لفرز الأجهزة ذات الاتجاه التصاعدي الأوضح، وقد تجاوزها هذان الجهازان فقط في الفحص المنفذ

ملاحظة منهجية : العتبة اختيار تحليلي وليست معيارا هندسيا معتمدا. كما لا يثبت الميل التصاعدي وجود تدهور ميكانيكي أو عطل وشيك، خاصة في مجموعة بيانات اصطناعية

7. التصورات البيانية — Data Visualization

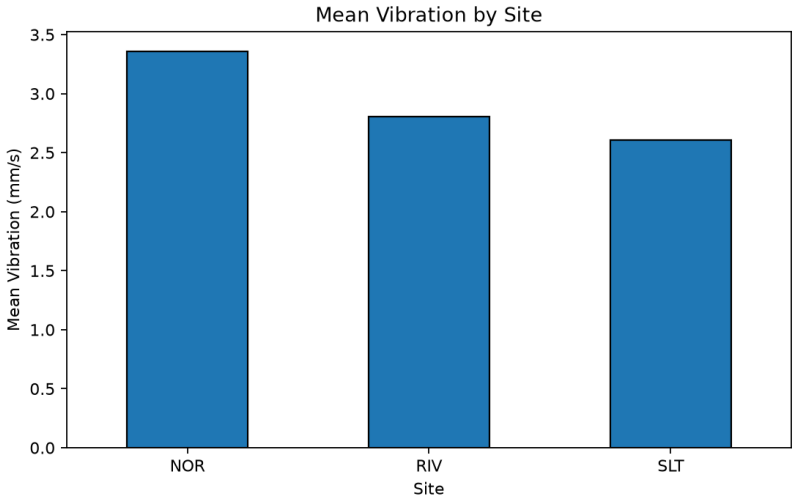
تم إنشاء أربعة مخططات مرتبطة بالنتائج السابقة وحفظها ضمن مجلد `charts`. تقدم الصور دعما بصريا للنتائج الرقمية، لكنها لا تحل محل الاختبارات أو الأدلة المنهجية

7.1 توزيع درجات الحرارة



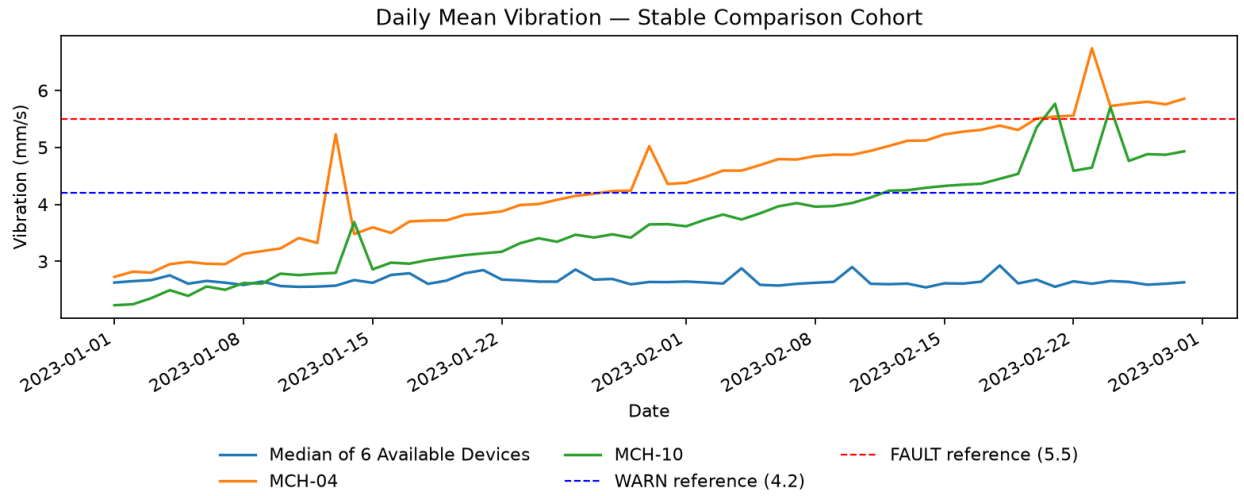
الشكل 1 : يعرض توزيع درجات الحرارة ومناطق تركز القراءات، ويساعد على قراءة الامتداد العام والقيم البعيدة عن الجزء الأكثر كثافة من التوزيع

7.2 متوسط الاهتزاز بحسب الموقع



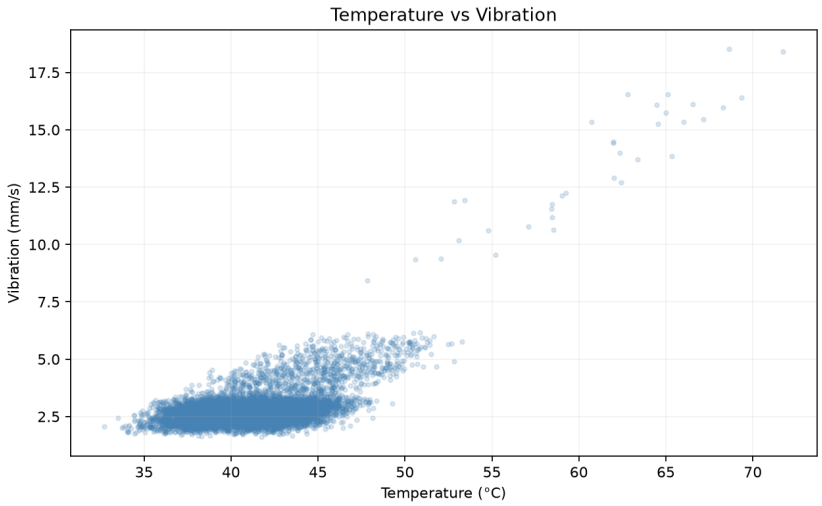
الشكل 2 : يوضح الفرق بين المتوسطات العامة للمواقع الثلاثة، ويكمل المقارنة التحليلية التي كشفت تأثير الجهازين ذوي القراءات المرتفعة على متوسط موقع `NOR`

7.3 الاتجاه اليومي للاهتزاز



الشكل 3 : يقارن الاتجاهات اليومية للجهازين MCH-04 و MCH-10 مع مجموعة مرجعية من ستة أجهزة ذات تغطية يومية كاملة، ويعرض المتوسط المرجعي لتسهيل المقارنة الوصفية

7.4 العلاقة بين الحرارة والاهتزاز



الشكل 4 : يوضح مخطط التشتت علاقة موجبة إجمالية بين المتغيرين، متسقة مع معامل ارتباط بيرسون المحسوب. ولا يمكن استنتاج علاقة سببية من شكل النقاط أو قيمة الارتباط وحدهما

8. المناقشة والاستنتاجات — Discussion & Findings

تظهر نتائج المشروع أن فحص البيانات لا يقتصر على حذف التكرارات أو توحيد تنسيق الأعمدة. إذ تؤثر جودة التسجيل وطريقة اختيار المجموعة المرجعية والحدود الإحصائية في المؤشرات والاستنتاجات المستخرجة

تتلخص أهم الاستنتاجات في النقاط الآتية :

1. **نجاح المعالجة القابلة للتحقق :** أزيلت التكرارات وعولجت اختلافات التنسيق دون تعويض مفقود أو حذف قراءات متطرفة دون مبرر
2. **تركز الاهتزاز المرتفع :** تساهم قراءات الجهازين `MCH-04` و `MCH-10` بدرجة كبيرة في القيم المتطرفة وفي متوسط موقع `NOR`
3. **حساسية تعريف القيمة المتطرفة :** تختلف نتائج IQR عند تغيير مرجع حساب الحدود، وقد تتغير هوية السجلات المصنفة حتى عندما تتطابق الأعداد الإجمالية
4. **اختلاف الارتباط بحسب مجموعة البيانات :** قيمة الارتباط العامة أعلى من القيمة المحسوبة ضمن القراءات المسجلة بالحالة `OK` فقط
5. **الفجوات ليست ناتجة بالضرورة عن المعالجة :** الفجوات الطويلة موجودة في المصدر الاصطناعي الأصلي، بينما يعتمد تقدير القراءات المحتملة غير المسجلة على افتراض انتظام التسجيل
6. **التحقق البرمجي لا يساوي التحقق الهندسي :** اتساق الأنواع والتصنيفات والملفات يثبت سلامة خطوات محددة، لكنه لا يحول التسميات والقياسات إلى دليل على أعطال فعلية

9. حدود الدراسة — Limitations

- البيانات اصطناعية وليست سجلات تشغيل حقيقية لمصنع، ولذلك لا يمكن تعميم النتائج على معدات فعلية دون تحقق خارجي
- لا تتوفر مواصفات فنية مستقلة للحساسات والأجهزة تثبت حدود التشغيل الآمن أو أسباب ارتفاع القياسات
- لا تثبت تسمية الحالة `FAULT` وقوع عطل ميكانيكي موثق
- تعتمد نتائج IQR على المجتمع المرجعي وتعريف الحدود المستخدمة، ولا تعني القراءات المتطرفة بالضرورة وجود أخطاء
- يعتمد تقدير القراءات غير المسجلة على الفواصل الزمنية المرصودة وليس على جدول تسجيل رسمي مثبت
- لا تثبت الارتباطات والاتجاهات اليومية العلاقات السببية أو القدرة التنبؤية
- لا يوفر المشروع سجلا مستقلا بأحداث الأعطال الفعلية أو توقيتها، ولم يتضمن تدريب نموذج تعلم آلة

10. التوصيات والتطوير المستقبلي — Recommendations

تدعم النتائج التوصيات التالية عند التعامل مع بيانات صناعية مشابهة :

1. **الاحتفاظ بالبيانات المرجعية والنسخة الخام :** لضمان التتبع وإمكان إعادة تنفيذ التنظيف والمقارنة
2. **توثيق قرارات التنظيف :** مع الفصل بين القيم غير الصالحة للتنسيق والقيم غير المعتادة إحصائيا
3. **استخدام حدود تشغيل معتمدة عند توفرها :** قبل تفسير القراءات المتطرفة على أنها أعطال فعلية
4. **التحقق من سياسة أخذ العينات :** للتمييز بين الفجوات التشغيلية والفواصل المسموح بها بين القياسات
5. **مراجعة مصدر تصنيفات الحالة :** قبل استخدام `status` هدفا تدريبيا في نماذج التصنيف

6. **التحقق من قابلية إعادة الإنتاج :** بإعادة تشغيل الدفترين ومقارنة المخرجات والملفات المحفوظة بالنتائج الموثقة

إمكانات التطوير : يمكن الاستفادة من البيانات المنظفة لاحقا في تجارب `Machine Learning` مثل تحليل الأنماط غير المعتادة. أما تطوير نموذج موثوق للصيانة التنبؤية فيستلزم تحديد هدف واضح ووجود بيانات مناسبة لأحداث الأعطال وتوقيتها وتصميم تقييم يمنع تسرب معلومات المستقبل `Data Leakage`

11. ملفات المشروع والمراجع — Project Files & References

الملف	المكون
`01_data_quality_analysis.ipynb`	دفتر فحص الجودة والتحليل
`02_data_cleaning_validation.ipynb`	دفتر التنظيف والتحقق
`original_data.csv`	البيانات الأصلية
`raw_data.csv`	البيانات الخام
`cleaned_data.csv`	البيانات المنظفة
`charts/`	المخططات
`README.md`	وصف المشروع وتعليمات إعادة التنفيذ
`requirements.txt`	بيئة التشغيل

المراجع :

- Datanemics — Factory Sensor Telemetry — مصدر مجموعة البيانات الاصطناعية ووصفها الفني
- Creative Commons — CC0 1.0 — نص الترخيص المعلن للمصدر
- دفاتر المشروع وملفات CSV المرفقة — مرجع الحسابات والتحليلات وإجراءات التحقق

12. الخلاصة — Conclusion

أنجز المشروع دورة متكاملة من **فهم البيانات وتقييم جودتها وتنظيفها والتحقق منها وتحليلها وعرض نتائجها**. أظهرت الاختبارات أن محتوى البيانات المنظفة والنسخة التحليلية متكافئ وفق شروط المقارنة، وأن النتائج الرقمية الأساسية قابلة لإعادة الحساب من ملفات المشروع

تشير النتائج إلى أن اختلاف سلوك بعض الأجهزة ووجود فجوات زمنية وقيم متطرفة أمور تستحق الدراسة، لكنها لا تكفي بمفردها لإثبات أسباب تشغيلية أو تشخيص أعطال. ومن ثم يمثل المشروع **أساسا موثقا لتحليل البيانات الصناعية** وخطوة تمهيدية لتجارب أكثر تقدما بعد استكمال البيانات والمعايير اللازمة